

NER wolof avec un CRF

Des phrases prêtes à prononcer, avec les cellules et fichiers à ouvrir au bon moment.

À DIRE À L'ORAL

« Bonjour. Notre projet porte sur la reconnaissance d'entités nommées en wolof. Notre objectif est d'identifier automatiquement les personnes, les lieux, les organisations et les dates. Pour cela, nous avons choisi un CRF, un modèle simple, rapide et adapté aux séquences. »

À MONTRER

Notebook : cellules 1-2
Titre du projet et objectif.

Quatre types : PER, LOC, ORG et DATE.

Type	À dire simplement	Exemple
PER	une personne	Maki Sàll
LOC	un lieu	Dakar
ORG	une organisation	ONU
DATE	une date	12 mars 2024

TRANSITION

« Avant de parler du modèle, je vais d'abord montrer comment les données sont organisées. »

1. Comprendre les données

À MONTRER

Notebook : cellules 5 à 11

Fichier : src/analyze_data.py

À DIRE À L'ORAL

« Nos données sont au format CoNLL. Chaque ligne contient un mot et son étiquette. Une ligne vide sépare deux phrases. Nous avons d'abord contrôlé les labels, l'alignement entre les mots et les réponses, puis la validité du format BIO. »

Label	Sens oral	Exemple
B-PER	début d'une personne	Maki
I-PER	suite de la même personne	Sàll
O	mot hors entité	dem
B-LOC	début d'un lieu	Dakar

SI LE JURY DEMANDE

Pourquoi vérifier BIO ?

Parce qu'un label I-PER ne doit pas apparaître sans un B-PER ou I-PER juste avant. Sinon, la séquence est incohérente.

SI LE JURY DEMANDE

Pourquoi ne pas utiliser seulement l'accuracy ?

Le label O est majoritaire. Un modèle pourrait prédire beaucoup de O et sembler bon, tout en ratant les vraies entités.

TRANSITION

« Une fois les données vérifiées, il faut les transformer en informations que le CRF peut apprendre. »

2. Transformer les phrases en X et y

À MONTRER

Notebook : cellules 12-13

Fichiers : src/features.py et src/dataset.py

À DIRE À L'ORAL

« X contient ce que le modèle observe. Pour chaque mot, nous décrivons sa forme, sa casse, ses préfixes, ses suffixes et ses voisins. y contient les bons labels BIO. Les deux séquences doivent garder exactement la même longueur. »

Ce que le CRF voit	Exemple	Pourquoi
mot en minuscules	sénégal	uniformiser la casse
préfixe et suffixe	sé / gal	repérer des formes
forme du mot	Xxxxxxx	voir majuscules et chiffres
mot avant et après	contexte local	désambiguïser
début ou fin	BOS / EOS	situer le mot

SI LE JURY DEMANDE

Que fait `prepare_split` ?

Elle appelle `sentence_features` pour construire X et copie les labels dans y. Elle ne mélange jamais les réponses avec les caractéristiques.

À DIRE À L'ORAL

« Le point important est l'alignement : le premier dictionnaire de X correspond au premier label de y, et ainsi de suite pour toute la phrase. »

TRANSITION

« *Maintenant que X et y sont prêts, nous pouvons entraîner le modèle.* »

3. Ce que le CRF apprend

À MONTRER

Notebook : cellules 14 à 17

Fichier : src/train_crf.py

À DIRE À L'ORAL

« Le CRF ne prédit pas chaque mot indépendamment. Il cherche la meilleure séquence complète de labels. Il combine deux informations : la compatibilité entre un mot et un label, appelée émission, et la compatibilité entre deux labels voisins, appelée transition. »

Notion	Formulation facile	Exemple
Émission	ce mot ressemble-t-il à ce type ?	majuscule → PER possible
Transition	ce label suit-il bien l'autre ?	B-PER → I-PER
Régularisation	éviter de trop mémoriser train	c1 et c2

À MONTRER

Configuration de départ

algorithm = lbfgs ; c1 = 0,1 ; c2 = 0,1 ; max_iterations = 100 ; all_possible_transitions = True.

SI LE JURY DEMANDE

Que fait fit() ?

fit() apprend les poids des caractéristiques et des transitions uniquement avec train. Dev et test ne participent pas à l'apprentissage.

TRANSITION

« Après l'apprentissage, nous vérifions d'abord les prédictions sur dev. »

4. Évaluer correctement le modèle

À MONTRER

Notebook : cellules 18 à 22

Fichier : src/evaluate.py

À DIRE À L'ORAL

« Nous utilisons segeval en mode strict IOB2. Une entité est correcte seulement si le type, le début et la fin sont tous exacts. Notre métrique principale est le F1, car il équilibre la précision et le rappel. »

Métrique	Question à poser	Erreur qui la baisse
Précision	mes prédictions sont-elles fiables ?	entités inventées
Rappel	ai-je retrouvé les entités attendues ?	entités manquées
F1	l'équilibre est-il bon ?	une précision ou un rappel faible

SI LE JURY DEMANDE

Exemple strict

Si la vérité est « Maki Sàll / PER » et que le modèle prédit seulement « Sàll / PER », l'entité est fausse car les limites sont différentes.

À DIRE À L'ORAL

« Sur dev, la configuration finale atteint un F1 strict de 0,7583. Ce score sert à comparer les configurations, pas à annoncer le résultat final. »

TRANSITION

« Nous allons maintenant voir comment cette configuration a été choisie sans utiliser test. »

5. Choisir puis tester sans tricher

À MONTRER

Notebook : cellules 26 à 31

Fichiers : src/select_crf.py et src/finalize_crf.py

À DIRE À L'ORAL

« Nous avons comparé quatre couples de régularisation sur dev. La meilleure configuration est c1 égal à 0,05 et c2 égal à 0,20. Après ce choix, nous l'avons figée, puis nous avons ouvert test une seule fois pour mesurer la généralisation. »

Mesure	Baseline dev	CRF dev	CRF test
F1 strict	0,6811	0,7583	0,6622

À DIRE À L'ORAL

« Le CRF dépasse la baseline sur dev. Sur test, le F1 baisse à 0,6622. Nous présentons cette baisse honnêtement : elle montre que les nouvelles données sont plus difficiles. »

SI LE JURY DEMANDE

Pourquoi test une seule fois ?

Si nous choisissons le modèle en regardant test, le score final serait biaisé. Train apprend, dev choisit, test juge.

SI LE JURY DEMANDE

Quels types sont les plus difficiles ?

LOC généralise bien. DATE et ORG ont surtout un rappel faible : beaucoup d'entités attendues sont manquées.

6. Expliquer les erreurs et les limites

À MONTRER

Notebook : cellules 23-25 et 37-39

Fichier : src/error_analysis.py

À DIRE À L'ORAL

« Nous ne nous sommes pas arrêtés au score. Nous avons classé les erreurs réelles de dev en quatre catégories : entité inventée, entité manquée, mauvais type et mauvaises limites. »

Erreur	Formulation orale	Conséquence
Inventée	le modèle voit une entité inexistante	précision baisse
Manquée	le modèle ne retrouve pas l'entité	rappel baisse
Mauvais type	bon texte, mauvaise catégorie	confusion PER/ORG/LOC/DATE
Mauvaises limites	segment trop court ou trop long	entité stricte fausse

À DIRE À L'ORAL

« La limite principale du CRF est son contexte local. Il comprend surtout la forme des mots et leurs voisins. Une entité rare ou jamais vue peut donc être manquée. »

SI LE JURY DEMANDE

Amélioration future

Comparer le CRF à un transformeur multilingue ou africain préentraîné, en gardant exactement le même découpage et le même F1 strict.

7. Se retrouver rapidement dans le code

N'ouvrez un fichier Python que si le jury demande le détail d'une étape.

Question du jury	Fichier à ouvrir	Cellules
Comment lisez-vous les données ?	analyze_data.py	5-11
Quelles caractéristiques utilisez-vous ?	features.py	12-13
Comment construisez-vous X/y ?	dataset.py	12-13
Comment entraînez-vous le CRF ?	train_crf.py	14-19
Comment calculez-vous le F1 ?	evaluate.py	20-22
Comment classez-vous les erreurs ?	error_analysis.py	23-25
Comment choisissez-vous c1/c2 ?	select_crf.py	26-28
Où faites-vous le test final ?	finalize_crf.py	29-31
Comment prédire une phrase ?	predict.py	32-33
Quelle est votre baseline ?	baseline.py	34-36
Que fait le mode assisté ?	postprocess.py	application
Où est l'interface ?	app.py	démonstration

À DIRE À L'ORAL

« Le notebook raconte le raisonnement dans l'ordre. Le dossier src contient les mêmes étapes sous forme de fonctions courtes et réutilisables. »

8. Présenter la démonstration Streamlit

À MONTRER

Fichiers : app.py, src/predict.py et src/postprocess.py

Lien : <https://5aaxfh5jf9kkjgjna7fpso.streamlit.app/>

À DIRE À L'ORAL

« L'application charge le modèle sauvegardé, découpe la phrase en tokens, construit les mêmes caractéristiques que pendant l'entraînement, puis affiche les labels BIO et les entités en couleur. »

Ordre de démo	Action	Ce que je dis
1	saisir une phrase	je donne un texte jamais codé dans l'interface
2	désactiver le mode assisté	voici le CRF brut évalué dans le notebook
3	activer le mode assisté	voici le bonus avec règles explicables
4	ouvrir le tableau BIO	chaque token reçoit exactement un label

SI LE JURY DEMANDE

CRF brut ou mode assisté ?

Le score scientifique vient toujours du CRF brut. Le mode assisté ajoute seulement des règles simples pour la démonstration : villes connues, sigles, dates et noms composés.

TRANSITION

« Pour terminer, je résume les résultats, les limites et la contribution du projet. »

9. Exposé complet en 90 secondes

À DIRE À L'ORAL

« Notre projet reconnaît quatre types d'entités dans un texte wolof : les personnes, les lieux, les organisations et les dates. Nous avons utilisé un corpus CoNLL avec des labels BIO. Après avoir contrôlé les données, nous avons transformé chaque mot en caractéristiques simples : forme, casse, préfixes, suffixes et voisinage. Le CRF apprend ensuite les associations entre ces caractéristiques et les labels, ainsi que les transitions entre labels successifs. Nous avons respecté le protocole train, dev, test : train pour apprendre, dev pour choisir c1 et c2, puis test une seule fois. Le CRF sélectionné obtient 0,7583 de F1 sur dev et 0,6622 sur test. Il dépasse la baseline de mémorisation sur dev. LOC généralise bien, mais DATE et ORG restent difficiles. Enfin, nous avons sauvegardé le modèle et créé une application Streamlit pour tester de nouvelles phrases. Notre solution est simple et interprétable, mais elle reste limitée par son contexte local. »

À MONTRER

Pendant ce résumé :

Notebook cellule 2 → cellule 13 → cellule 15 → cellule 21 → cellule 30 → application.

PHRASE DE CONCLUSION

« Ce projet montre surtout un protocole propre, une évaluation stricte, une analyse honnête des erreurs et une application directement testable. »

10. Réponses courtes aux questions probables

Question	Réponse prête à prononcer
Pourquoi un CRF ?	Il traite la phrase comme une séquence et apprend les transitions BIO.
Que contient X ?	Les caractéristiques de chaque token, organisées phrase par phrase.
Que contient y ?	Les labels BIO attendus, alignés avec les tokens.
Que fait fit() ?	Il apprend les poids des caractéristiques et des transitions sur train.
Pourquoi le F1 ?	Il équilibre les entités inventées et les entités manquées.
Pourquoi le mode strict ?	Le type et les limites doivent être exacts pour valider une entité.
Pourquoi une baseline ?	Elle montre si le CRF fait mieux qu'une simple mémorisation.
Pourquoi le score test baisse ?	Les cas test sont moins bien couverts, surtout DATE et ORG.
Le mode assisté compte-t-il ?	Non. Le score vient du CRF brut ; les règles sont un bonus de démo.
Quelle suite ?	Comparer à un transformeur avec le même protocole et la même métrique.

RÈGLE D'OR

Répondre d'abord en une phrase simple. Ouvrir ensuite la cellule ou le fichier qui prouve la réponse.
Ne pas réciter tout le code si le jury ne le demande pas.